



**AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA
W KRAKOWIE**

Sprawozdanie - laboratorium nr 10

*Poszukiwanie minimum wartości funkcji w dwóch wymiarach
metodą Newtona*

Klaudia Fil, 12.05.2019 r.

1. Wstęp teoretyczny

Zadaniem optymalizacji jest poszukiwanie minimum lub maksimum funkcji, w praktyce oznacza to sprowadzenie do poszukiwania tylko tego pierwszego, czyli takiego punktu w

$f: R^n \rightarrow R$, dla którego zachodzi:

$$\min f(x) = f(x') \Leftrightarrow \forall f(x') < f(x) \quad , \quad (1)$$

$$x = [x_1, x_2, \dots, x_n]^T \quad (2)$$

z warunkami:

$$g_j(x) \leq 0, j = 1, 2, \dots, m \quad , \quad (3)$$

$$h_j(x) = 0, j = 1, 2, \dots, r \quad , \quad (4)$$

gdzie funkcje $f(x), g(x), h(x)$ są funkcjami skalarnymi, pierwsza to funkcja celu, a dwie następne określają warunki jakie musi spełnić rozwiązanie (więzy).

Gradient funkcji celu $f(x) \in C^2$ definiujemy:

$$g(x) = \nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix} . \quad (5)$$

Macierzą Hessego, czyli Hesjanem dla funkcji celu $f(x) \in C^2$ nazywamy:

$$H(x) = \left\{ \frac{\partial^2 f(x)}{\partial x_i \partial x_j} \right\} = \nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \dots & \dots \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \dots & \dots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix} . \quad (6)$$

Minimum globalne funkcji stanowi taki x' , dla którego:

$$\forall f(x) \geq f(x') \quad , \quad \text{dla } x \in R^n \quad (7)$$

Minimum lokalne funkcji stanowi taki x' , dla którego:

$$\exists \epsilon: \epsilon > 0, \epsilon \in R \rightarrow \forall f(x) > f(x'), \text{ dla } x: \|x - x'\| \leq \epsilon \quad (7)$$

Punktem siodłowym $x' = \begin{pmatrix} x^0 \\ y_0 \end{pmatrix}$ funkcji nazywamy taki punkt, który:

$$\exists \epsilon: \epsilon > 0, \epsilon \in R \rightarrow \forall f(x, y^0) \leq f(x^0, y^0) \leq f(x^0, y) \text{ dla } x: \|x - x^0\| \leq \epsilon \text{ i } y: \|y - y^0\| \leq \epsilon \quad (8)$$

Jednym z rodzajów metod poszukiwania minimum funkcji, są metody kierunkowe, dla których definiujemy różniczkę zupełną jako iloczyn skalarny wektorów:

$$df = \frac{\partial f}{\partial x_1} dx_1 + \dots + \frac{\partial f}{\partial x_n} dx_n = \nabla f(x) dx \quad (9)$$

Kiedy wektor u wyznacza kierunek prostej łączącej punkty x i x' to są one powiązane:

$$x(\lambda) = x' + \lambda u, \quad (10)$$

natomiast dla bardzo małych wartości λ możemy zapisać:

$$dx = u d\lambda \quad (11)$$

Na prostej łączącej ustalone punkty x i x' wartość funkcji celu zależna będzie od nowej zmiennej λ :

$$F(\lambda) = f(x' + \lambda u) = f(x), \quad (12)$$

licząc różniczkę zupełną dla funkcji celu zależnej od λ :

$$dF = df = \nabla^T f(x) u d\lambda \quad (13)$$

Możliwe jest wyznaczenie pochodnej kierunkowej funkcji celu w x dla kierunku u :

$$\frac{dF(\lambda)}{d\lambda} = \frac{df(x)}{d\lambda} \Big|_u = \nabla^T f(x) u \quad (14)$$

Metodą Newtona poszukiwania minimum funkcji kwadratowej w R^n wykorzystując następująco zdefiniowaną funkcję:

$$f(x) = \frac{1}{2} x^T A x + x^T b + c, \text{ gdzie} \quad (15)$$

A jest pewną macierzą kwadratową oraz $a, b \in R^n$, $c \in R$.

Gdy A jest macierzą symetryczną to zachodzi:

$$\nabla f(x) = Ax + b, \text{ oraz } \nabla^2 f(x) = A \Rightarrow H(x) = A \quad (16)$$

Jeśli A jest dodatniookreślona to rozwiązanie można łatwo znaleźć, ponieważ

$$\nabla f(x) = Ax + b = 0, \text{ a więc} \quad (17)$$

$x' = -A^{-1}b$ - macierz dodatniookreślona, nieosobliwa dlatego można ją odwrócić.

W tej metodzie zakładamy:

$$x' = x^i + \delta, \text{ gdzie } x^i - \text{ przybliżone rozwiązanie w } i\text{-tej iteracji.} \quad (18)$$

Wykorzystując szereg Taylora możemy zapisać:

$$0 = \nabla f(x') = \nabla f(x^i + \delta) = \nabla f(x^i) + H(x^i)\delta + O(\|\delta\|^2), \quad (19)$$

wtedy w i -tej iteracji poprawiamy rozwiązanie $x^{i+1} = x^i + \delta$ i ostatecznie:

$$x^{i+1} = x^i - H^{-1}(x^i) \nabla f(x^i). \quad (20)$$

2. Zadanie do wykonania

2.1. Opis problemu

Celem ćwiczenia jest znalezienie miejsca zerowego funkcji:

$$f(x, y) = x^2 - 4x + 8 + y^2 - 4y + xy, \quad (21)$$

jednak po zauważeniu że wykres ten jest przesunięty o stałą 8, możemy zdefiniować nową funkcję, której wyznaczymy minimum:

$$g(x, y) = f(x, y) - 8 = x^2 - 4x + y^2 - 4y + xy. \quad (22)$$

Wykorzystując metodę Newtona (15) - bez stałej:

$$g(r) = \frac{1}{2} r^T A r + r^T b, \quad (23)$$

gdzie $r^T = [x, y]$, A to macierz Hessego, $b = [b_1, b_2]$ jest wektorem wyrazów wolnych.

Znajdujemy macierz A , ze wzoru (6):

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad (24)$$

oraz bazując na wzorze (23) obliczamy $b = [-4, -4]$.

Dla porównania należy sporządzić wykres konturowy $g(x, y)$ w przedziale $x \in (-10, 10)$, $y \in (-10, 10)$ i na jego podstawie określić przybliżone minimum.

Następnie dla punktów startowych $(0,0), (10,-10), (100,100), (500,500)$ wyznaczyć minimum metodą Newtona, oraz określić ilość iteracji.


Ostatnią częścią jest wprowadzenie wagi ω do wzoru (20):

$$x^{i+1} = x^i - \omega H^{-1}(x^i) \nabla f(x^i) , \quad (25)$$

oraz wyznaczenia dla minimum dla stałego punktu $(10,10)$, przyjmując wagi $\omega=0.1, 0.4, 0.7$.

2.2. Wyniki

Dzięki programowi w języku C, oraz wykorzystując skrypt Gnupłota wygenerowano:



Rysunek 1.: Wykres konturowy na tle mapy wartości funkcji $g(x, y)$. Czerwonym krzyżykiem

zaznaczono dokładne minimum funkcji: $x_{min} = \frac{4}{3}, y_{min} = \frac{4}{3}$.

Ponieważ funkcja jest kwadratowa podjęto próbę wyznaczenia gotowego rozwiązania znajdując macierz odwrotną do A , gdzie wyszło $\vec{r}_{min} = \begin{pmatrix} 1.33333 \\ 1.33333 \end{pmatrix}$ co zgadza się z odczytanymi z rys. 1 danymi.

(x_0, y_0)	Liczba iteracji	x_{min}	y_{min}
(0, 0)	2	1.33333	1.33333
(10, -10)	2	1.33333	1.33333
(100, 100)	2	1.33333	1.33333
(500, 500)	2	1.33333	1.33333

Tabela 1. Wyniki poszukiwania minimum funkcji (x_{min}, y_{min}) dla różnych punktów startowych (x_0, y_0) . W drugiej kolumnie podano liczbę iteracji wykonanych przed uzyskaniem zbieżności.

Ilość iteracji w tabeli 1. dla każdego punktu startowego wynosi tyle samo i jest stosunkowo mała, wyniki są zgodne z wykresem konturowym, algorytm dla wagi $\omega = 1$ jest efektywny.

(ω)	Liczba iteracji	x_{min}	y_{min}
0.1	135	1.33334	1.33334
0.4	32	1.33333	1.33333
0.7	15	1.33333	1.33333

Tabela 2. Wyniki poszukiwania minimum funkcji (x_{min}, y_{min}) przy różnych wartościach wagi ω dla punktu startowego $(x_0, y_0) = (10, 10)$. W drugiej kolumnie podano liczbę iteracji wykonanych przed uzyskaniem zbieżności.

Kiedy jednak zmienimy wagę zgodnie z wzorem (25) część, którą odejmujemy jest mała przez co ilość iteracji jest największa dla najmniejszej wagi i analogicznie odwrotnie proporcjonalna podczas zwiększania ω .

3. Wnioski

Metoda Newtona w naszym przypadku dla wagi równej 1 jest bardzo efektywna i niezależna od wartości punktu startowego, co jest ogromnym plusem, wystarczyło zaledwie 2 iteracje. Kiedy jednak waga maleje zwiększa się ilość iteracji, a co za tym idzie ukazują się minusy metody:

- konieczność wyznaczania hesjanu w każdym punkcie, problem z liczeniem pochodnych, jeśli nie analitycznie to numerycznie, co może skutkować błędami przybliżenia,
- nie zawsze jest zbieżna nawet w pobliżu minimum, co skutkuje potrzebą nałożeniem kolejnych warunków, spadkiem efektywności algorytmu.